

Métodos de Agrupamento Aprendizagem de Máquina 2026

André Luiz Brun¹

¹Colegiado de Ciência da Computação
Campus de Cascavel - UNIOESTE

Resumo. *Este documento consiste na especificação formal do segundo trabalho da disciplina de Aprendizagem de Máquina (Csc4026) para o ano letivo de 2026. Aqui são apresentadas as atividades a serem desenvolvidas e como cada processo deverá ser realizado. Além disso, o documento contém as informações sobre a formação das equipes, o objeto de trabalho de cada uma e as datas de entrega e apresentação dos relatórios.*

1. Introdução

O objetivo do segundo trabalho da disciplina consiste em comparar o comportamento, em termos de competência, de métodos de agrupamento baseados em diferentes conceitos sobre uma mesma base de dados. Como critério de avaliação serão computadas as medidas intrínsecas de coesão, separação, coeficiente de silhueta. Além disso, serão avaliadas as métricas de homogeneidade, completude, entropia e índice randômico para o comportamento de cada método de agrupamento.

Espera-se, através da execução dos experimentos, que cada equipe possa identificar a abordagem que foi mais adequada ao seu conjunto de dados de acordo com as medidas de desempenho levantadas.

2. Implementação

Nesta seção é descrito como cada etapa do desenvolvimento deve ser realizada segundo os conceitos vistos durante a disciplina. Deverão ser implementadas uma estratégia hierárquica (**Aglomerativa**), uma abordagem baseada em densidade (**DBScan**) e outra com foco em centralidades (**K-means**).

2.1. Análise descritiva dos dados

Cada equipe ficará encarregada de uma base de dados distinta. No entanto, todas as bases adotadas terão 2000 instâncias e serão compostas por dois atributos do tipo real. O número de classes entre as bases, no entanto, pode variar entre 2 e 4 classes.

As bases estão foram distribuídas aleatoriamente para cada equipe e disponibilizadas, em formato .csv através dos links disponíveis na Seção 3. Cada equipe terá seu link específico, de acordo com o arquivo que lhe é destinado.

2.2. Treinamento e Calibração dos Modelos

Como pretendemos agrupar todas as instâncias do conjunto de entrada em um determinado número de clusters, o processo de ajuste dos parâmetros se dará sobre todo o conjunto de dados, sem a necessidade de separação entre treino, teste e validação. Assim, os

valores mais adequados aos parâmetros serão aqueles que possibilitarem a obtenção das melhores métricas.

IMPORTANTE: A escolha dos hiperparâmetros deve ser feita com base nos índices de avaliação e não a partir do conhecimento prévio sobre os dados. Caso as métricas indiquem, por exemplo, que um número de clusters diferente do original seja mais indicado, essa configuração deve ser a escolhida.

Uma vez que cada estratégia possui seus próprios parâmetros a serem definidos, na Tabela 1 estão detalhados quais deles devem ser refinados para cada método de agrupamento.

Tabela 1. Conjunto de parâmetros a serem calibrados

Método	Hiperparâmetros
K-means	n_clusters
	max_iter
DBScan	eps
	min_samples
AGNES (Agglomerative)	n_clusters
	linkage

2.3. Avaliação dos Modelos

Definidos os melhores parâmetros para cada método de clustering, o passo seguinte consiste em estimar as medidas de avaliação especificadas. Para cada uma das três abordagens deverão ser obtidas as métricas descritas a seguir:

- Intrínsecas
 - Coesão
 - Separação
 - Coeficiente de Silhueta Médio
- Extrínsecas
 - Homogeneidade
 - Índice Randômico
 - Índice Randômico Ajustado (ARI)
 - Completeness
 - V-Measure
 - Entropia

2.4. Análise Comparativa

Esta etapa consiste na comparação das medidas de desempenho dos métodos para descobrir qual deles se sobressaiu.

De acordo com o comportamento dos dados de entrada ou dos parâmetros dos modelos, quais seriam as métricas mais interessantes para seu trabalho? Embase a sua justificativa.

Dentre as métricas escolhidas, comparando-se os modelos de agrupamento, qual seria o mais indicado? Por que razão?

NOTA: A equipe deverá apresentar uma análise comparativa evidenciando qual modelo se sobressaiu. Uma vez que diversas medidas de desempenho são utilizadas, não embasem as decisões em apenas uma delas.

2.5. Como fazer?

Não é necessário implementar os métodos de agrupamento. Neste caso, pode-se e é indicado, que sejam utilizadas implementações prontas dos métodos, ficando a carga da dupla apenas a implementação do framework e análise dos parâmetros e resultados.

3. Equipes

Na Tabela 2 são apresentadas as composições de cada equipe bem como o problema sobre qual cada uma trabalhará. Além disso, são apresentados os endereços eletrônicos onde as bases de dados podem ser obtidas.

Tabela 2. Formação das equipes e conjunto de dados para o trabalho

ID	Equipe	Fonte
1	Ellen Cristini Schreiber Brzozoski Lóra João Leonardo Lívero Lavaqui	link
2	Lucas Batista Campos	link
3	Maria Eduarda Amorim Quevedo	link
4	Hermes Soares de Jesus Paulo Roberto Bomfim Rosa	link
5	Bruno Felipe Lovato Fabio Kenji Sato	link
6	André Gustavo Franco Matheus Barros	link
7	Arthur Angelo Cenci Silva Vinicius Eduardo Morais Oliveira	link

4. O que deve ser entregue

4.1. Relatório

Deve ser elaborado um relatório técnico em formato pdf contendo:

- Detalhamento de quais foram os parâmetros empregados em cada método de clustering e em qual faixa de valores cada parâmetro foi variado. Por exemplo, no K-means, seria possível variar o valor de k entre 1 e 10;
- Análise detalhada das métricas de desempenho (internas e externas) obtidas para cada modelo;
- Análise pertinente indicando quais métricas melhor representam o desempenho dos algoritmos perante o conjunto de entrada;
- Comparação adequada e embasada das três estratégias de agrupamento testadas;

- Análise dos clusters formados e *insights* sobre observações pertinentes.

O formato do relatório deve ser a formatação presente neste texto. As regras para tal podem ser obtidas no link [download](#). No arquivo disponível pode-se utilizar a formatação em arquivo .doc ou em latex.

4.2. Código-fonte

Além do relatório citado, cada equipe deverá enviar os códigos-fonte construídos para a execução dos experimentos. Ambos arquivos podem ser compactados e enviados como arquivo único.

5. Para quando?

O trabalho deverá ser submetido no link disponibilizado na turma de disciplina dentro do ambiente Microsoft Teams até as **12:00 do dia 12/16/2026**.

As apresentações serão realizadas na aula do dia 15/06/2026.

Cada grupo terá até 15 minutos para apresentar o trabalho realizado, focando na descrição do problema, nos desempenhos obtidos e na comparação dos desempenhos alcançados.